



Ementa – Dia 2: Embeddings, RAG e OpenAI na prática

Bem-vindos ao segundo dia do nosso workshop sobre Inteligência Artificial e Automação com n8n. Hoje, vamos falar um pouco das capacidades da OpenAI para além do que é comum, focando em embeddings, RAG e como estas tecnologias podem ser aplicadas de forma prática e eficaz nos vossos projetos.



por **Guilherme Souza**

Objetivo do Dia 2

1 OpenAI vs. Gemini em Embeddings e RAG

Compreender a superioridade da OpenAI na geração de embeddings e a sua aplicação prática em sistemas RAG (Retrieval-Augmented Generation).

2 Introdução ao OpenWebUI

Conhecer o OpenWebUI como uma alternativa visual e intuitiva para gerir as vossas interações com modelos de IA.

3 Explorando o Playground da OpenAI

Dominar a utilização do Playground da OpenAI para criar e testar embeddings e desenvolver assistentes inteligentes personalizados.

4 Construindo um Fluxo Funcional

Montar um pipeline prático utilizando OpenWebUI, n8n, OpenAI e uma base de conhecimento, demonstrando a integração destas ferramentas.



Comparativo: OpenAI vs Gemini

Característica	OpenAI	Gemini
Embeddings	text-embedding-3-small e large (superiores em benchmark)	Sem foco direto em embeddings vetoriais
Integração via API	Documentada, robusta e fácil de usar	Mais limitada e menos flexível para casos de uso específicos
Playground	Completo, interativo e visual	Limitado em funcionalidades e interatividade
Suporte a RAG nativo	Sim, com assistentes e ferramentas dedicadas	Não direto, exige adaptação e desenvolvimento adicional

Conclusão: Para RAG e projetos que dependem fortemente de vetores, a OpenAI é atualmente a escolha mais eficaz e direta.

O que é RAG? (Retrieval-Augmented Generation)

RAG é uma técnica inovadora que combina a inteligência de modelos de IA generativa com a precisão de sistemas de busca baseados em bases de dados vetoriais. Isto permite que os modelos respondam a perguntas complexas com informações relevantes e atualizadas, superando as limitações dos modelos que apenas utilizam o seu conhecimento pré-treinado.

Vetorização de Documentos

Transformação de documentos em embeddings vetoriais que capturam o seu significado semântico.



Consulta Semântica

Pesquisa por similaridade para recuperar os trechos mais relevantes da base de conhecimento.

Geração da Resposta

Utilização dos trechos recuperados para gerar uma resposta precisa e contextualizada pela IA generativa.

Exemplos práticos de aplicação de RAG incluem FAQs inteligentes, análise aprofundada de documentos jurídicos ou médicos, e chatbots que fornecem informações específicas e verificáveis.


OpenAI Playground: Usos e Vantagens

O OpenAI Playground é um ambiente visual e interativo que serve como um laboratório para experimentar e desenvolver soluções com IA.

Permite:

- **Testar Prompts:** Iterar rapidamente na criação e otimização de prompts para obter os resultados desejados.
- **Criar Assistentes:** Desenvolver assistentes personalizados com acesso a ferramentas como embeddings, ficheiros e código.
- **Geração de Embeddings:** Criar embeddings de texto de forma simples para alimentar as vossas bases de dados vetoriais.
- **Upload de Documentos:** Integrar documentos para conversas inteligentes e simular o comportamento do vosso bot em cenários reais.

É uma ferramenta indispensável para prototipagem e validação de ideias, permitindo uma compreensão profunda do potencial dos modelos de linguagem da OpenAI.



Assistants da OpenAI

Os Assistants da OpenAI são mais do que simples modelos de linguagem; são agentes programáveis que podem interagir com o mundo através de ferramentas. Cada Assistant possui uma identidade, um propósito e um conjunto de capacidades.



Nome e Objetivo

Define a persona e a finalidade do assistente, como "Assistente de Suporte ao Cliente" ou "Consultor Financeiro".



Comportamento

Regras e diretrizes que moldam como o assistente processa informações e interage com os utilizadores.



Ferramentas Conectadas

Integração com bases de dados de embeddings, ficheiros externos, e funções personalizadas para expandir as suas capacidades.

Exemplo de Uso: Um assistente configurado para responder a todas as dúvidas sobre editais públicos, utilizando como base o conteúdo de PDFs carregados previamente. Este assistente pode analisar grandes volumes de texto e extrair informações precisas, facilitando a vida de candidatos e gestores.

Subindo o OpenWebUI (Interface Visual via Docker)

Para quem procura uma interface visual intuitiva para interagir com modelos de IA localmente ou em produção, o OpenWebUI é uma excelente opção. É uma alternativa leve e de código aberto, com uma experiência de utilizador muito similar ao ChatGPT.

```
docker pull ghcr.io/open-webui/open-webui:main
```

```
docker run -d -p 3000:8080 -v open-webui:/app/backend/data --name  
open-webui ghcr.io/open-webui/open-webui:main
```

- **Interface Amigável:** Design limpo e familiar, facilitando a navegação e a interação.
- **Compatibilidade Ampla:** Suporta não só OpenAI, mas também LM Studio, Ollama e outros modelos, oferecendo flexibilidade.
- **Ideal para Testes e Produção:** Perfeito para prototipagem rápida e para implementação em ambientes de produção com requisitos de interface simples.

Mais informações em: [OpenWebUI QuickStart](#)

Exemplo de Fluxo com n8n + OpenAI

Vamos explorar um fluxo prático que demonstra a conexão entre n8n e OpenAI para criar um sistema de resposta inteligente. Este exemplo ilustra como integrar estas ferramentas para automatizar interações complexas.



Webhook Recebe Pergunta

O fluxo inicia com um webhook do n8n, que capta uma pergunta do WhatsApp ou outra plataforma de mensagens.



HTTP Request Busca Vetores

Uma requisição HTTP é enviada para a base de dados vetorial, buscando informações relevantes com base na pergunta.



OpenAI Gera a Resposta

A OpenAI utiliza os trechos recuperados para gerar uma resposta coerente e contextualizada.



Envio da Resposta

A resposta gerada é enviada de volta ao utilizador, seja via WhatsApp, Telegram ou outro canal.

Este tipo de fluxo é fundamental para construir chatbots avançados e sistemas de suporte ao cliente automatizados.

Resumo do Dia



OpenAI superior para RAG

A OpenAI destaca-se na criação de embeddings e no suporte a RAG, oferecendo ferramentas mais robustas e eficientes para projetos baseados em vetores.



Playground e Assistants facilitam

O Playground e a funcionalidade de Assistants simplificam drasticamente o processo de uso e prototipagem de modelos de IA, tornando-o acessível mesmo para iniciantes.



OpenWebUI: ótima interface

O OpenWebUI oferece uma interface gráfica excelente para testes locais e interação com múltiplos modelos de IA, melhorando a experiência do utilizador.

Próximo passo:

Desenvolver o problema proposto com essas ferramentas